

(Proposta) Modelo de Fusão de Dados Multissensoriais com Incerteza para a Consciência Situacional de Agentes

MunIQUE MittelmANN¹, Jerusa Marchi¹, Aldo von Wangenheim¹

¹Departamento de Informática e Estatística – Universidade Federal de Santa Catarina (UFSC)
Florianópolis – SC – Brazil

munyquee@gmail.com, jerusa.marchi@ufsc.br, aldo.vw@ufsc.br

1. Proposta

O trabalho propõe um modelo de Fusão de Dados com Incerteza para atingir a Consciência Situacional de um agente ao nível de Percepção. O modelo abrange os níveis de Funcionais de Fusão de Dados (FFD) Avaliação de Sinais (0-FFD), Avaliação de Entidades (1-FFD) e Avaliação de Situações (2-FFD). Para esclarecer a proposta, é introduzido um cenário de exemplo na Seção 1.1. O cenário de exemplo é acompanhado em paralelo ao detalhamento da proposta. A Figura 1 introduz uma visão geral do modelo de Fusão de Dados, ilustrando sua relação com os modelos de SA e FFD. Os estágios do modelo são especificadas durante as Seções 1.2, 1.3 e 1.4.




Figura 1. Modelo de Fusão de Dados com Incerteza

1.1. Exemplo de Cenário de Aplicação

Considere a existência de um robô cujo objetivo é limpar os cômodos de uma casa. Como cada cômodo demanda equipamentos de limpeza distintos, o robô precisa saber em qual cômodo está. A casa é composta por dois quartos (Q_1 e Q_2 , respectivamente) e dois corredores conectando os quartos (C_1 e C_2 , respectivamente).

O robô caminha aleatoriamente pela casa e não conhece a disposição de seus cômodos. A Figura 2(a), ilustra a distribuição de Q_1 , Q_2 , C_1 e C_2 pela casa. Para perceber o ambiente, o robô possui apenas sensores para captar sons, luminosidade e distância (sensor ultrassônico). Com estes sensores, o robô precisa descobrir, respectivamente, se o barulho do ambiente é alto ou baixo (Figura 2(b)), se o ambiente está claro ou escuro (Figura 2(c)) e se o espaço entre as paredes é amplo ou apertado (Figura 2(d)). Observa-se que as informações sensoriais são classificadas por variáveis linguísticas providas de imprecisão por vagueza (alto e baixo, claro e escuro, amplo e apertado).

Antes de ser posto em funcionamento, o robô recebeu informações amostrais sobre mapeamentos anteriores do ambiente. Assim, ele conhece a probabilidade *a priori* de estar em cada cômodo, bem como as probabilidades condicionais de estar com barulho

alto ou baixo, em um ambiente claro ou escuro e em um espaço amplo ou apertado dado que está em algum cômodo específico. As Figuras 2(b), 2(c) e 2(d) ilustram, respectivamente, a distribuição do barulho, iluminação e espaço pela casa em um determinado momento. Os valores das medições de som, luminosidade e distância podem variar dependendo do momento, seja por causa de falha sensorial ou de mudança no ambiente.

Munido apenas das informações sensoriais e das probabilidades *a priori* e condicionais, o robô deve decidir em qual cômodo está e, assim, ser capaz de determinar seus planos de ação. Durante a apresentação da proposta, o cenário do robô limpador é retomado de modo a exemplificar a aplicação e os níveis do modelo.

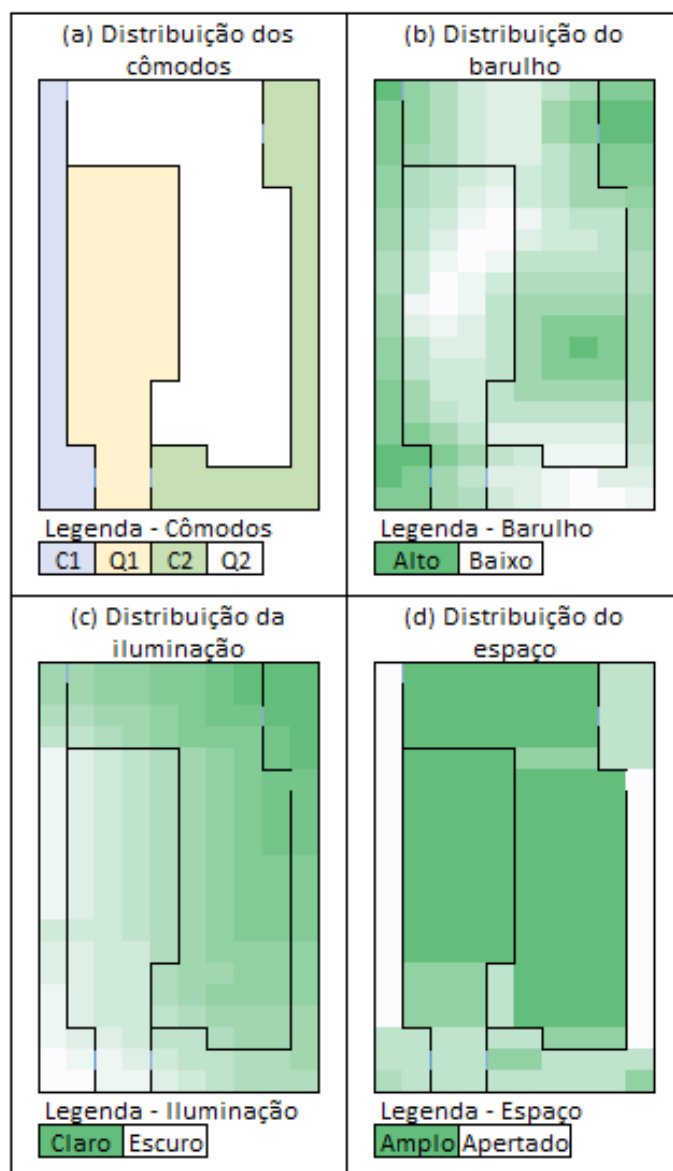


Figura 2. Cenário do Robô Limpador

1.2. Nível de Avaliação de Sinais

Considerando o nível de Avaliação de Sinais, o Agente possui um conjunto $\mathcal{S}_T = \{S_{T_1}, \dots, S_{T_n}\}$ de sensores, onde T representa o tipo de sensor e $S_{T_i} = \{s_1, \dots, s_n\}$ re-

presenta um conjunto de sensores físicos de mesmo tipo. Para cada S_{T_i} são obtidos conjuntos M_i de medidas, de forma que $\mathcal{M} = \bigcup_{i \in T} M_i$ forma o conjunto de todos os sinais percebidos pelo agente.

O robô limpador da Seção 1.1 possui três tipos de sensores: luminosidade, distância e sonoro, ou seja: $\mathcal{S}_{T_{robo}} = \{S_{luz}, S_{distancia}, S_{som}\}$. O robô possui um sensor de luminosidade, dois de distância e um sonoro, assim $S_{luz} = \{s_{luz}\}$, $S_{distancia} = \{s_{d1}, s_{d2}\}$, com s_{d1} e s_{d2} sendo, respectivamente, os sensores de distância da direita e da esquerda do robô, e $S_{som} = \{s_{som}\}$. As medidas obtidas pelos sensores são $\mathcal{M}_{robo} = \{m_{luz}, m_{d1}, m_{d2}, m_{som}\}$. A Figura 3 ilustra o nível de Avaliação de Sinais para o Robô Limpador.

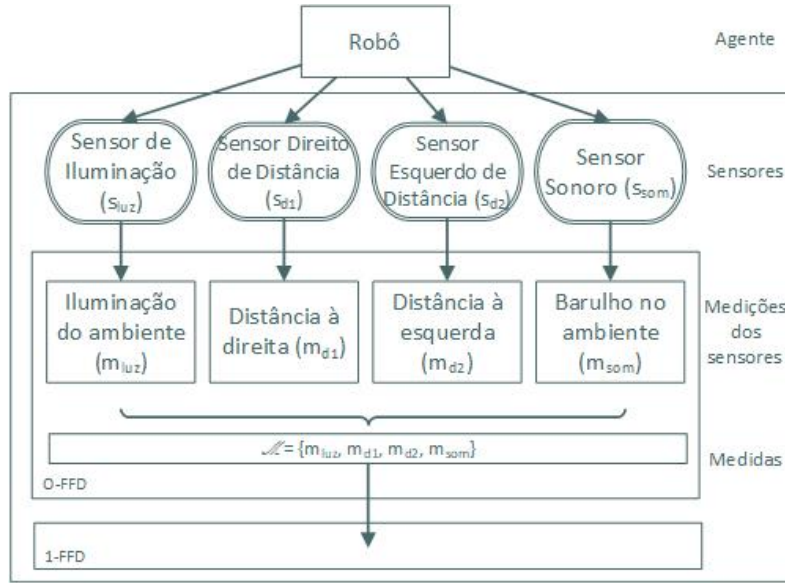


Figura 3. Nível de Avaliação de Sinais (0-FFD) no Cenário do Robô Limpador

1.3. Nível de Avaliação de Entidades

No nível de Avaliação de Entidades, ocorre a transformação dos dados de medidas em evidências observadas. A transformação das medidas é definida como a aplicação de uma função $f(x) \rightarrow \mathbb{R}$ sobre os mesmos, onde $f \in \{A, R\}$ é uma função de Agregação ou Replicação, $x \in 2^{\mathcal{M} \setminus \emptyset}$ ¹ é a aridade da função. Cada função $f(x)$ gera uma nova evidência observada $o_k \in \mathbb{R}$, na qual k representa um domínio (ex.: distância, iluminação, barulho).

A função de Agregação A é realizada por meio de operações sobre uma ou mais as medições pertencentes a \mathcal{M} e é definida por $A(m_i, \dots, m_j) \rightarrow \mathbb{R}$, com $(m_i, \dots, m_j) \in 2^{\mathcal{M} \setminus \emptyset}$. A função de Replicação R realiza cópia de um elemento de \mathcal{M} , tal que $R(m_i) \rightarrow \mathbb{R}$, com $m_i \in \mathcal{M}$.

Sobre o_k é aplicado o operador de normalização, tal que $N : \mathbb{R} \rightarrow [0, 1]$. Tal operação visa facilitar o suporte de cada evidência observada, entretanto, não é necessário realizar a normalização. Para fins de simplificação da notação, continuaremos a denominar a evidência observada normalizada de o_k . Consideraremos $\mathcal{O} = \bigcup_{\forall k} o_k$ o conjunto global de evidências.

¹ $2^{\mathcal{M} \setminus \emptyset}$ representa o conjunto das partes de \mathcal{M} sem o conjunto vazio \emptyset .

No cenário do Robô Limpador, as medições m_{d1} e m_{d2} são agregadas tal que $o_{espaco} = \| m_{d1} \| + \| m_{d2} \|$ ². Ou seja, o espaço entre as paredes o_{espaco} é a soma da distância da parede à direita do robô com a distância da parede à esquerda do robô. As medições m_{luz} e m_{som} são replicadas como evidências observadas, tal que $o_{luz} = m_{luz}$ e $o_{som} = m_{som}$. Nota-se que $\mathcal{O}_{robo} = \{o_{luz}, o_{espaco}, o_{som}\}$ é o conjunto normalizado de todas as evidências observadas pelo robô.

Em seguida, ocorre a estimação dos estados das observações por meio de lógica Fuzzy. Considerando para cada domínio K um universo de discurso no intervalo $[0, 1]$ ³ denotado por \mathcal{A}_k , para cada $o_k \in \mathcal{O}$ será calculado o valor de pertinência a algum conjunto fuzzy A_k , definido sobre $\mathcal{A}_k = \{A_{k1}, \dots, A_{kn}\}$, com $1 \leq i \leq n$. O grau de pertinência de o_k ao conjunto A_{k_i} é denotado por $\mu_{A_{k_i}}(o_k)$.

O conjunto de todos os graus de pertinência $\mu_{A_{k_i}}(o_k)$, $\forall A_{k_i} \in \mathcal{A}_k$ e $\forall o_k \in \mathcal{O}$ é denotado por:

$$\mu(\mathcal{O}) = \bigcup_{\forall k, \forall i} \mu_{A_{k_i}}(o_k)$$

Para cada evidência observada pelo Robô Limpador, foi definido um universo de discurso e calculados os graus de pertinência da evidência a cada conjunto do universo de discurso. Para o_{luz} , $\mathcal{A}_{luz} = \{claro; escuro\}$. Para o_{espaco} , $\mathcal{A}_{espaco} = \{amplo; apertado\}$. Para o_{som} , $\mathcal{A}_{som} = \{baixo; alto\}$. A seguir, para cada evidência o_k observada pelo robô, foi estimado seu grau de pertinência $\mu_{A_{k_i}}(o_k)$ para cada conjunto $A_{k_i} \in \mathcal{A}_k$ (Figura 4).

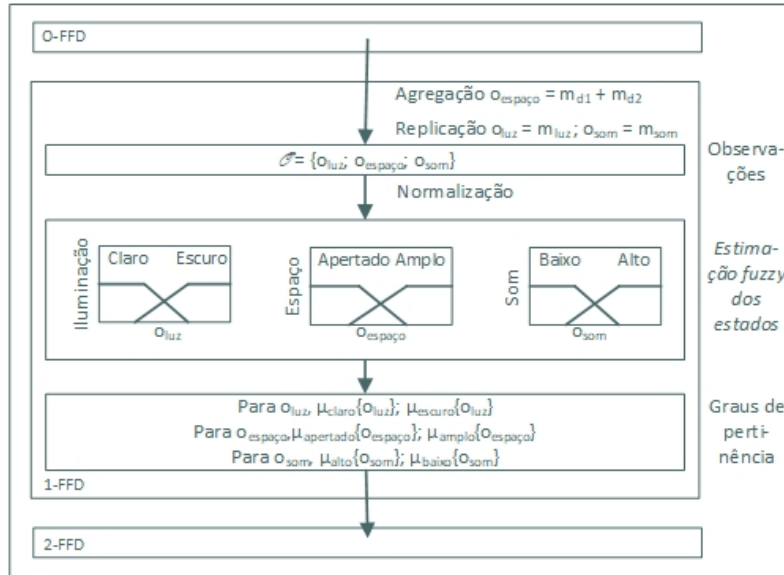


Figura 4. Nível de Avaliação de Entidades (1-FFD) no Cenário do Robô Limpador

1.4. Nível de Avaliação de Situação

No nível de Avaliação de Situação, os graus de pertinência das observações $\forall \mu_{A_{k_i}}(o_k) \in \mu(\mathcal{O})$, são considerados as evidências de um Raciocinador Fuzzy-Bayesiano (RFB).

² $\| x \|$ representa o módulo de um número $x \in \mathbb{R}$.

³ $[0, 1]$ se normalizado, se não $[\min(O), \max(O)]$.

Sendo $\mathcal{H} = \{H_1, \dots, H_n\}$ o conjunto de hipóteses sobre Z , Z como a situação na qual o agente está, $P(H_h) \rightarrow [0; 1]$ representa a probabilidade *a priori* da h -ésima hipótese e $P(o_k|H_h) \rightarrow [0; 1]$ é a probabilidade de observar o_k dada a hipótese H_h . A probabilidade da hipótese H_h ajustada pela imprecisão sobre todas as observações $o_k \in \mathcal{O}$ é denotada por $\tilde{P}(H_h|\mathcal{O})$ e definida conforme a equação de [Brignoli et al. 2015] (fundamentação teórica), tal que:

$$\tilde{P}(H_h|\mathcal{O}) = \frac{\prod_{k=1}^{|\mathcal{O}|} \sum_{i=1}^n (P(o_k|H_h) * \mu_{A_{k_i}}(o_k))}{\sum_{l=1}^{|\mathcal{H}|} \prod_{k=1}^{|\mathcal{O}|} \sum_{i=1}^n (P(o_k|H_l) * \mu_{A_{k_i}}(o_k))}$$

A probabilidade ajustada pela imprecisão $\tilde{P}(H_h|\mathcal{O})$ é estimada $\forall H_h \in \mathcal{H}$.

A situação avaliada no cenário da Seção 1.1 é a localização atual do robô, ou seja $Z_{robo} = Local$. As hipóteses são as possibilidades de localização, os cômodos da casa, então $\mathcal{H}_{robo} = \{H_{Q_1}; H_{Q_2}; H_{C_1}; H_{C_2}\}$. Assim, $P(H_h)$ representa as probabilidades *a priori* do robô estar em cada cômodo da casa. $P(o_k|H_h)$ são as probabilidades condicionais dos estados de uma observação, ou seja $o_k = luz, som$ ou $espaco$, sabendo-se que está em determinado cômodo (H_h).

Para o Robô Limpador, o RFB descobre as probabilidades $\tilde{P}(H_h|\mathcal{O})$ de estar em cada cômodo $\forall H_h \in \mathcal{H}_{robo}$ dadas as evidências observadas pelo robô $\mathcal{O}_{robo} = \{o_{luz}, o_{espaco}, o_{som}\}$.

A última etapa do modelo é denominada Gerador de Crenças (GC). Considera-se que o conjunto de hipóteses \mathcal{H} são as implicações das relações entre as observações, ou seja, a conclusão do que o agente está observando. Assim, para cada hipótese $H_h \in \mathcal{H}$, o GC gera uma crença em lógica proposicional tal que:

$$Z(H_h, \tilde{P}(H_h|\mathcal{O}))$$

Representa que o agente acredita que a situação atual Z é H_h com $\tilde{P}(H_h|\mathcal{O})$ certeza. $G_h = \tilde{P}(H_h|\mathcal{O})$ é considerado o grau de certeza do agente em relação a hipótese H_h .

Para cada cômodo da casa, o GC do Robô Limpador gera uma crença em lógica proposicional com o grau de certeza que o robô tem de estar no cômodo. A Figura 5 ilustra o nível de avaliação de situação no cenário do Robô Limpador.

- É intuitivo que o Agente deva considerar, durante a Compreensão e Projeção, a crença na qual possui mais certeza. Entretanto, incluir as crenças para todas as hipóteses permite que o agente reaja a situações nas quais nenhuma crença tenha um grau de certeza razoável.

- Por exemplo, considere um grau de certeza na crença C_1 de 51% e em C_2 de 49%. Estes valores indicam que o agente tem preferência em acreditar em C_1 . Entretanto, como a diferença do grau de certeza entre as crenças é baixa, existe grande incerteza em relação a situação. A propagação desta incerteza permite considerá-la nos planos do agente. Suponha que o agente deva realizar a ação A_1 quando está na situação descrita por H_1 . Ao invés de executar A_1 imediatamente, o agente pode reagir de acordo com

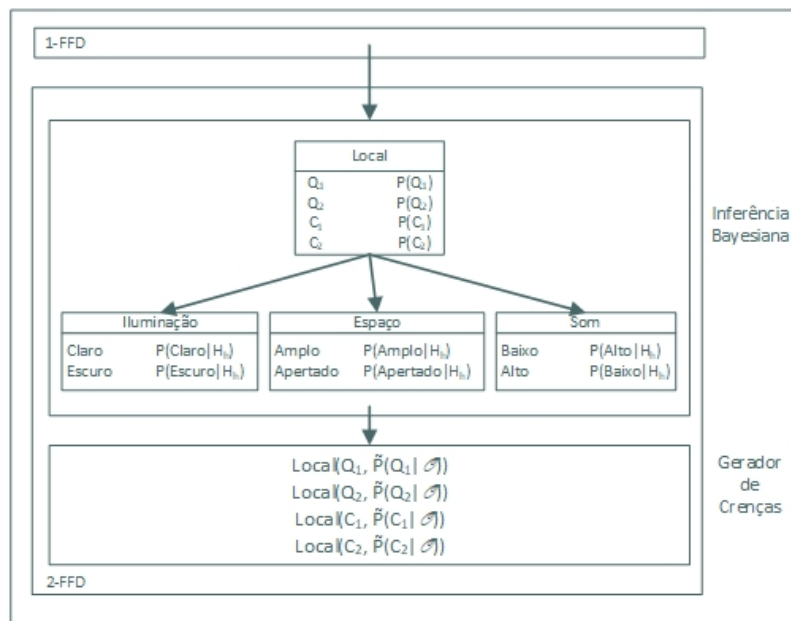


Figura 5. Nível de Avaliação de Situação (2-FFD) no Cenário do Robô Limpador

a incerteza: esperar uma nova informação sensorial, consultar outro agente, entregar o controle da ação a um humano, etc.

2. Considerações

- Uma das vantagens: a rede bayesiana estima a probabilidade mesmo se não forem observadas todas as evidências, então se um sensor falhar, as crenças do agente ainda serão formadas, mesmo que com um grau de certezas inferiores (ou menos precisos?).

- Problema: Na abordagem fuzzy-bayesiana, a crença de saída não é fuzzy e não é possível usar a rede como um regressor (desfuzzificar). Prejudica agentes que precisem fazer uso da crença fuzzy para controlador. A crença fuzzy permitiria a realimentação de crenças em uma rede bayesiana de duas camadas ou mais (do modo que está).

- Problema : "the phenomenon under observation may be time-invariant or varying with time. In the latter case, it may be necessary for the data fusion algorithm to incorporate a recent history of measurements into the fusion process"(survey 2 - data fusion)

Referências

Brignoli, J. T., Pires, M. M., Nassar, S. M., and Sell, D. (2015). A fuzzy-Bayesian model based on the superposition of states applied to the clinical reasoning support. *IntelliSys 2015 - Proceedings of 2015 SAI Intelligent Systems Conference*, pages 210–219.